NPU 탑재 MCU 의 상시 음향 이벤트 감지에서 전처리 위치가 정확도와 에너지에 미치는 영향: MAX78000 실측

Where Should the Front-End Go? Measured Accuracy–Energy Trade-offs of Preprocessing Placement for Always-On Acoustic Event Detection on an NPU-Equipped MCU (MAX78000)

요 약

NPU 를 탑재한 MCU(MAX78000) 에서 배터리 상시 구동 음향 이벤트 감지기를 구현하고, 로그 멜 전처리를 어디에 둘지가 정확도와 판단당 에너지에 미치는 영향을 실측했다. 벤더 참조 설계처럼 원파형을 NPU 에 직접 넣어 전처리를 없앤 구성은 CPU 로그 멜 구성보다 시험셋 macro-F1 이 0.166 낮았고, 필터뱅크·로그 압축을 NPU 연산으로 옮긴 변형들은 이 격차를 되찾지 못했다. 반면 프레임 간격을 넓힌 거친 로그 멜을 CPU 에 남기고 작은 2D CNN 을 NPU 에 올린 구성은 원파형 구성보다 macro-F1 이 +0.085 높으면서 (Welch 95% CI 가 0 을 포함하지 않음) 추정 에너지는 같거나 적었다. NPU 추론은 같은 가중치의 CMSIS-NN 추론보다 판단 1 회 기준 89 배 빨랐다. 전처리 위치는 가속기 친화성의 문제가 아니라 정확도–에너지 설계 변수이며, 최적점이 양 끝이 아닌 중간에 있음을 보인다.

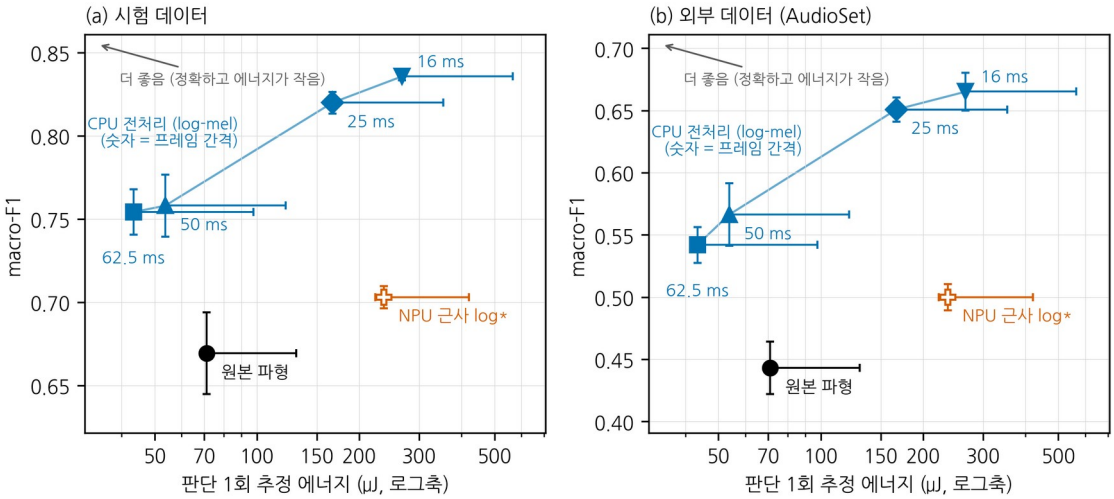


그림 1. 판단 1 회 추정 에너지(가로, 로그축)와 정확도. (a) 시험 데이터 macro-F1, (b) 외부 데이터 F1. 색은 전처리 위치, 마커 위치는 데이터시트 전력 기준, 가로 막대는 공개 전력값 범위, 세로 막대는 시드 표준편차(n=3). NPU 근사 log(*) 는 보드 미실측으로 지연을 합성 사이클로 추정한 점.

표 1. 주 결과. 정확도는 시드 1~3 평균 ± 표준편차, 오경보 300 회/h. 지연은 보드 1,000 회 최악값, 에너지는 추정(실측 지연 × 공개 전력).

구성	판단 1 회 지연 (ms)	에너지 µJ, 추정 (데이터시트 / Moosmann)	macro-F1 시험 데이터	F1 외부 데이터
원본 파형 (전처리 없음)	2.53	71 / 78	0.669 ± 0.025	0.443 ± 0.021
NPU 근사 log	6.59 (추정)	236 / 223	0.703 ± 0.007	0.500 ± 0.011
CPU log-mel, 간격 62.5 ms (멜 32)	2.93	43 / 78	0.754 ± 0.014	0.542 ± 0.014
CPU log-mel, 간격 50 ms	3.66	54 / 98	0.758 ± 0.019	0.566 ± 0.025
CPU log-mel, 간격 25 ms	9.42	167 / 261	0.820 ± 0.006	0.651 ± 0.010
CPU log-mel, 간격 16 ms	15.06	267 / 418	0.836 ± 0.002	0.665 ± 0.015
CPU 추론 (Cortex-M4F) (원 파형 가중치)	225.77	2008 / 5599	= 원본 파형	= 원본 파형

1. 서 론

소형 MCU 에 신경망 가속기(NPU)를 얹은 칩이 늘고 있다. MAX78000 은 Cortex-M4F 와 CNN 가속기를 한 칩에 두어 상시 동작 음향 감지에 적합하지만, 가속기는 합성곱·풀링·요소별 연산만 지원하고 FFT·로그 같은 전처리 연산은 지원하지 않는다. 따라서 로그 멜 전처리는 CPU 가 맡거나, 아예 없애고 원파형을 가속기에 직접 넣어야 한다. 벤더의 음성 키워드 참조 설계는 후자를 택하며 음성에서는 정확도 손실이 거의 없다고 알려져 있다 [1].

본 연구는 이 선택이 환경음(사이렌·유리 파손·비명·개 짖음) 감지에서도 성립하는지를 같은 데이터·같은 학습 설정·같은 보드에서 실측으로 답한다. 기여는 셋이다. (1) 전처리 위치를 양 끝(전부 CPU, 전부 NPU)과 그 사이의 여섯 구성으로 나누어 정확도와 판단 1 회 지연을 보드에서 재고 에너지를 추정한 정확도–에너지 곡선. (2) 필터뱅크·로그 압축·분할 등 전처리를 NPU 연산으로 옮긴 변형이 원파형 구성을 유의하게 넘지 못한다는 부정 결과. (3) 거친 로그 멜(프레임 간격 62.5 ms, 멜 32)을 CPU 에 남기는 구성

이 원파형 구성을 정확도와 에너지 양쪽에서 이긴다는 관찰과, 전처리가 NPU 가 처리할 데이터량을 줄이는 단계라는 해석.

2. 관련 연구

MAX78000 의 자원·전력 특성은 Moss 등 [2] 이, 키워드 인식의 초저전력 구현은 Ulkar 와 Okman [3] 이, 물체 검출은 Moosmann 등 [4] 이 보고했다. 이들은 전처리를 고정한 채 모델을 다룬다. 원파형에서 직접 배우는 프론트엔드로는 SincNet [5] 과 LEAF [6] 가 있으나 로그·PCEN 같은 비선형 압축을 포함하므로 MAX78000 가속기에 그대로 올릴 수 없다. CPU 추론 대조군은 CMSIS-NN [7] 으로 구현했다. 데이터는 FSD50K [8]·UrbanSound8K [9]·ESC-50 [10] 과 AudioSet [11] 을 썼고, 대형 모델 기준선과 증류 교사로 PANNs [12] 를 썼다.

3. 시스템과 실험 설계

시스템. MAX78000FTHR 단독으로 온보드 마이크 16 kHz 입력을 1.024 s 창(16,384 샘플, int8)으로 받아 250 ms 마다 5 클래스(사이렌·유리 파손·비명·개 짖음·배경)를 판단한다. 모델은 가중치 8 bit QAT, 가속기 가중치 메모리 442 KB 안에 들어간다.

데이터와 정답. 세 공개 데이터셋은 모두 Freesound 파생이라 원본 ID 단위로 전역 분할해 누수를 막았고, AudioSet 의 실환경 녹음 구간을 학습에 더했다. 시험셋의 유리·비명 창은 저자가 전수 청취해 양성을 확정했다(채점 창 4,965). 외부 평가는 AudioSet 의 별도 영상에서 뽑은 673 창(양성 271, 음성 402) 으로, 학습에 쓰지 않았다. 오경보율은 시험셋 배경에서 300 회/h 가 되는 문턱값을 잡아 외부에도 같은 값을 썼고, 지표는 macro-F1 이다.

구성. 원본 파형 (전처리 없음): 원파형을 128×128 로 접어 1D CNN 에 넣는 벤더 방식. NPU 근사 log: 로그 압축을 NPU 안의 구간선형 층으로 근사한 1D 구성. CPU log-mel 네 구성: 프레임 간격 62.5 ms(멜 32)·50 ms(멜 32)·25 ms(멜 64)·16 ms(멜 64) 의 증분 로그 멜을 CPU 가 계산하고 2D CNN 을 NPU 에 올린다. CPU 추론: 원본 파형 (전처리 없음) 의 가중치를 그대로 CMSIS-NN 으로 Cortex-M4F 에서 돌린 대조군(NPU 출력과 비트 일치). 모든 구성은 같은 데이터로 150 에폭, 같은 스케줄·증강·교사 증류(PANNs 임베딩 위 선형 프로브)로 시드 3 개씩 학습했다.

지연과 에너지. 지연은 보드에서 SysTick 으로 1,000 회 재어 최악값을 보고한다(전원 투입 직후, 코어 100 MHz, CNN 50 MHz). 에너지는 외부 계측 장비 없이 E = t전처리·Pcpu + (t적재 + t출력)·Pload + t추론·Pnpu 로 추정했으며, 전력값은 데이터시트와 동일 칩 실측 선행연구 [2–4] 두 출처를 나란히 써 범위로 보고한다. 측정값이 아님을 모든 수치에 밝힌다.

4. 결 과

전처리 제거의 비용. 원본 파형 구성은 CPU log-mel 16 ms 구성보다 시험 macro-F1 이 0.166, 외부 F1 이 0.222 낮다(표 1). 음성 키워드에서 손실이 없던 선택이 환경음에서는 큰 비용을 치른다. 같은 가중치를 CPU 로 돌린 CMSIS-NN 대조군과 비교하면 NPU 추론은 추론만 157 배, 판단 1 회 89 배 빠르고 CPU 추론은 판단 주기의 90% 를 추론에 쓴다(그림 2).

NPU 로 옮긴 전처리는 되찾지 못한다. NPU 근사 log 는 원본 파형 구성 대비 +0.034 [-0.022, +0.090] 로 CI 가 0 을 포함하고, 로그 근사 층 때문에 NPU 사이클이 3.8 배 늘어 추정 에너지는 3.3 배다. 앞선 라운드(v1 데이터)에서 시험한 변형들도 같았다: 멜 필터뱅크 초기화 Conv1d + Abs (D-1) -0.026 [-0.057, +0.006]; D-1 탭 256 / 512 (k=2 / k=4) -0.050 / -0.032; NPU 구간선형 로그 ((a), v1) +0.003 [-0.028, +0.034]; NPU 필터뱅크 + CPU 정수 로그 분할 ((c)) -0.012 [-0.042, +0.018]; 원파형 2D 재배열 (wave2D) -0.019. 본 데이터에서 멜 대역폭에 맞춘 512 탭 필터뱅크에 프레임 안 시간 에너지 적분(8 위치 합)을 더해 선형 전처리를 전부 NPU 로 옮긴 구성(3 시드)도 원본 파형 구성 대비 -0.026 [-0.082, +0.030], 같은 분류기·같은 32×16 격자의 CPU log-mel 62.5 ms 구성 대비 -0.111 [-0.162, -0.060] 로 열세였다. 선형 부분만 옮겨도 정확도를 잃고, 지원하지 않는 비선형을 합성곱으로 흉내 내는 순간 NPU 는 CPU 보다 비싸진다.

최적점은 중간에 있다. CPU log-mel 62.5 ms 구성은 원본 파형 구성보다 시험 macro-F1 +0.085 [+0.035, +0.135], 외부 F1 +0.099 [+0.056, +0.142] 로 유의하게 높고, 판단 1 회 지연은 2.93 ms 대 2.53 ms 로 비슷하며, 추정 에너지는 데이터시트 기준 43 대 71 μJ 로 적고 Moosmann 기준 78 대 78 μJ 로 같다. 이유는 그림 2 에 있다. 로그 멜이 16,384 샘플을 512 값으로 줄이므로 NPU 추론이 1.44 ms 에서 0.53 ms 로 줄고, CPU 전처리 2.26 ms 가 그 차이보다 작다. 전처리는 병목이 아니라 데이터 축소 단계였고, NPU 가 원시 샘플 전량을 처리하는 순간 그 이득이 사라진다. 프레임 간격을 좁힐수록 정확도는 오르지만 (CPU log-mel 25 ms 0.820 ± 0.006, CPU log-mel 16 ms 0.836 ± 0.002) 전처리가 지연의 2/3 를 차지해 에너지가 6 배가 된다. CPU log-mel 25 ms 와 CPU log-mel 16 ms 의 차이는 -0.016 [-0.030, -0.002] 로 작지만 0 을 포함하지 않았다.

대형 모델 기준선. 같은 정답·같은 문턱값 규칙으로 PANNs(CNN14) 를 채점하면 시험 macro-F1 0.845 이다. CPU log-mel 16 ms 구성은 그 99% 에 이른다.

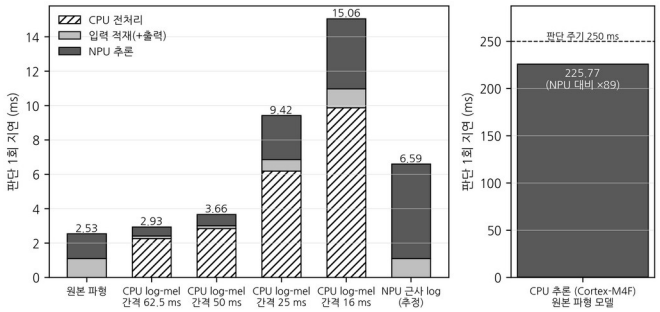


그림 2. 판단 1 회 지연 분해(보드 실측, 1,000 회 최악값). 왼쪽은 NPU 추론 여섯 구성(CPU 전처리 / 입력 적재 / NPU 추론), 오른쪽은 같은 가중치의 CPU 추론(Cortex-M4F, CMSIS-NN)과 판단 주기 250 ms.

5. 한계와 결론

한계. 에너지는 직접 계측하지 않은 추정값이며 전력 출처에 따라 결론의 강도가 다르다(CPU log-mel 62.5 ms 구성의 우위는 '적다' 와 '같다' 사이). 시드가 3 개라 신뢰구간이 넓다. 정답 청취는 저자 1 인이다. 비명과 환호의 경계는 음향만으로 가를 수 없어 비명 재현율은 그 모호성을 포함한다. 시험셋 배경의 절반이 하드 네거티브라 오경보율은 실배치보다 부풀려져 있다. 음량 정

규화·필터 해상도·용량 확대 등 원파형 쪽 변형을 더 시도할 여지는 남아 있다.

결론. NPU 탑재 MCU 에서 '전처리를 전부 가속기로' 는 환경음 감지에서 최적이 아니다. 지원 연산이 제한된 가속기에 비선형 전처리를 옮기는 시도는 정확도도 에너지도 얻지 못했고, 작은 CPU 전처리로 데이터량을 줄인 뒤 작은 모델을 가속기에 올리는 구성이 정확도–에너지 전선 위에 있었다. 가속기 설계 지침은 연산 위치가 아니라 가속기에 들어가는 데이터율을 기준으로 세워야 한다.

참고문헌

[1] Analog Devices, "ai8x-training: KWS20 v3 reference," github.com/analogdevicesinc/ai8x-training, 2023.

[2] A. Moss, H. Lee, L. Xun, C. Min, F. Kawsar, A. Montanari, "Ultra-low power DNN accelerators for IoT: resource characterization of the MAX78000," Proc. SenSys Workshop AIChallengeIoT, 2022.

[3] M. G. Ulkar, O. E. Okman, "Ultra-low power keyword spotting at the edge," arXiv:2111.04988, 2021.

[4] J. Moosmann, M. Giordano, C. Vogt, M. Magno, "TinyissimoYOLO: a quantized, low-memory and ultralow-power object detection network for microcontrollers," Proc. IEEE AICAS, 2023.

[5] M. Ravanelli, Y. Bengio, "Speaker recognition from raw waveform with SincNet," Proc. IEEE SLT, pp. 1021–1028, 2018.

[6] N. Zeghidour, O. Teboul, F. de Chaumont Quitry, M. Tagliasacchi, "LEAF: a learnable frontend for audio classification," Proc. ICLR, 2021.

[7] L. Lai, N. Suda, V. Chandra, "CMSIS-NN: efficient neural network kernels for Arm Cortex-M CPUs," arXiv:1801.06601, 2018.

[8] E. Fonseca, X. Favory, J. Pons, F. Font, X. Serra, "FSD50K: an open dataset of human-labeled sound events," IEEE/ACM TASLP, vol. 30, pp. 829–852, 2022.

[9] J. Salamon, C. Jacoby, J. P. Bello, "A dataset and taxonomy for urban sound research," Proc. ACM Multimedia, pp. 1041–1044, 2014.

[10] K. J. Piczak, "ESC: dataset for environmental sound classification," Proc. ACM Multimedia, pp. 1015–1018, 2015.

[11] J. F. Gemmeke et al., "Audio Set: an ontology and human-labeled dataset for audio events," Proc. ICASSP, pp. 776–780, 2017.

[12] Q. Kong, Y. Cao, T. Iqbal, Y. Wang, W. Wang, M. D. Plumbley, "PANNs: large-scale pretrained audio neural networks for audio pattern recognition," IEEE/ACM TASLP, vol. 28, pp. 2880–2894, 2020.